

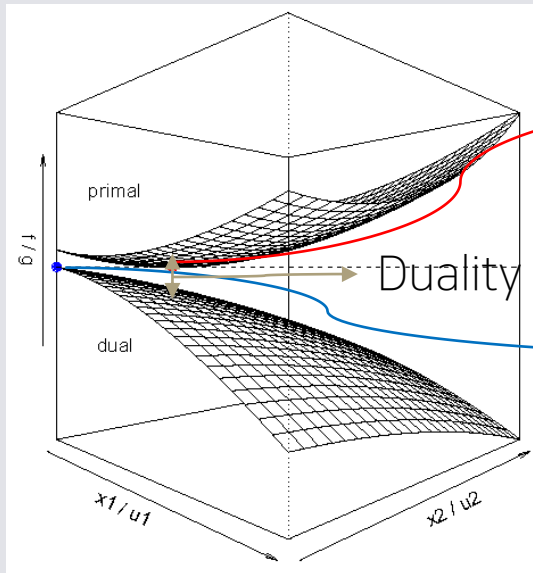


# Duality

# Duality(optimization)

[https://en.wikipedia.org/wiki/Duality\\_\(optimization\)](https://en.wikipedia.org/wiki/Duality_(optimization))

- 수학에서 최적화 이론에서 이중성 혹은 이중성 원리는 최적화 문제를 **primal problem** 혹은 **dual problem** 의 두 관점에서 볼 수 있다는 원칙.
- Dual problem 의 솔루션은 primal problem 즉, 최소화 문제의 솔루션의 **lower bound** 를 제공함.
- 하지만, 일반적으로 primal 과 dual problem 의 최적화된 값은 동치가 아니며 이를 **duality gap** 이라고 부름.
- convex optimization problem 에서, duality gap 은 **constraint qualification** 조건하에서 0 임.



최적의 primal value

Primal 을  
dual 로 바꾸  
어 풀 수 있음.

최적의 dual value

목표는 조건이 주어진 최소화 문제에서 최대화 문제로 근사하여 최솟값을 찾겠다는 것으로 핵심은 **주어진 조건을 포함하는 하나의 식**으로 만들어 주는 것임. 최소화 문제에서 최적의 최솟값을 찾으려 하는 강력한 lower bound 를 가지는  $g(u)$  찾는 것이 목표임.

- Dual 함수,  $g(u)$  는 0 이상의 모든  $u$  에 대하여  $f^*$  즉, primal 의 최적 값에 대한 lower bound 를 제공함.

<Example of quadratic program in 2D>

# Dual problem(Lagrange dual problem) 의 개요

- 다음과 같이 주어진 선형 조건을 만족시키면서 선형인 목적함수  $c^T x$  를 최소화 하는 문제(primal problem) 가 주어져 있다고 가정.


$$\min_x \quad c^T x$$

$$\begin{aligned} Ax &= b \\ Gx &\leq h \end{aligned}$$

$$\max_{u,v} \quad -ub^T - vh^T$$

$$\begin{aligned} \text{subject to} \quad & (-uA^T - vG^T)^T = c \\ & v \geq 0 \end{aligned}$$

Primal  
problem



Dual  
problem

라그랑주 승주법에서 만족해야 하는 조건 2가지

양변에  $u^T$ 와  $v^T$ 를 곱하여줌. ( $v \geq 0$ )

$$u^T Ax + v^T Gx \leq u^T b + v^T h$$

$$(u^T A + v^T G)x \leq u^T b + v^T h$$

$$(uA^T + vG^T)^T x \leq u^T b + v^T h$$

$$(-uA^T - vG^T)^T x \geq -u^T b - v^T h$$

$$(-uA^T - vG^T)^T = c \text{ 일 때,}$$

$$\therefore c^T x \geq -u^T b - v^T h$$

$c^T x$  Lower bound(하한) 이  $-u^T b - v^T h$  임.

따라서, 을 최대화 하는 dual problem 으로 primal problem 이 치환 될 수 있음.


# 라그랑주 승주법

---

- 라그랑주 승수법이란?
- 프랑스의 수학자 조세프루이 라그랑주 (Joseph-Louis Lagrange)가 제약 조건이 있는 최적화 문제를 풀기위해 고안한 방법임.
- 라그랑주 승수법은 어떠한 문제의 최적점을 찾는 것이 아닌 최적점이 되기 위한 조건을 찾는 방법으로 즉, 최적해의 필요조건을 찾는 방법임.
- 핵심 아이디어
- 최적화 하려는 값에 형식적인 라그랑주 승수를 더하여, 제약된 문제를 제약이 없는 문제로 문제를 접근 하였음.

# 라그랑주 승주법의 기하학적인 접근 방식

- 두 함수의 공통 접선이 최대, 최소 문제를 해결할 수 있는 핵심 아이디어가 될 수 있다는 것에서 시작함.
- 즉, 라그랑주 승수법의 기본 가정은 다음과 같음.
- “제약 조건  $g$  를 만족하는  $f$  의 최솟값 혹은 최댓값은  $f$  와  $g$  가 접하는 곳에 존재할 수도 있다.”



- 제약조건  $g(x,y) = c$  와  $f(x,y)$ 가 접할때 제약 조건을 만족하는  $f(x,y)$  는 최대가 됨.

이렇게 접하는 지점의 특징은 제약 조건  $g(x,y) = c$  와  $f(x,y) = k$  의 접선이 같다는 점임.

즉, 서로의 normal vector 가 평행한 point 임!

# 라그랑주 승주법의 기하학적인 접근 방식

- 이러한 관찰을 바탕으로 수식화를 해보면 다음과 같음.

$$\nabla f = \lambda \nabla g$$

두 함수의 gradient vector 가 평행하다!  
즉, 내적을 0 이며 scaling factor,  $\lambda$  만을 통해서 서로를 표현 할 수 있음을 의미함.

$$\nabla f - \lambda \nabla g = \nabla L = 0 \leftarrow (\text{내가 수식화 한 부분이라 맞는지 잘 모르겠음,,,})$$

$$L(x, y, \lambda) = f(x, y) - \lambda(g(x, y) - c)$$


➡ 정의된 함수  $L$  의 gradient vector 가 영벡터가 되는 지점을 찾는 문제로 주어진 식  $\nabla f = \lambda \nabla g$  을 수식화 할 수 있음.

이제,  $\frac{dL}{dx}, \frac{dL}{dy}$ ,  $g(x, y) = c$  총 제약조건 3개로 함수  $L(x, y, \lambda)$  를 해결 할 수 있음.

각  $x, y$  에 대한  
편 미분

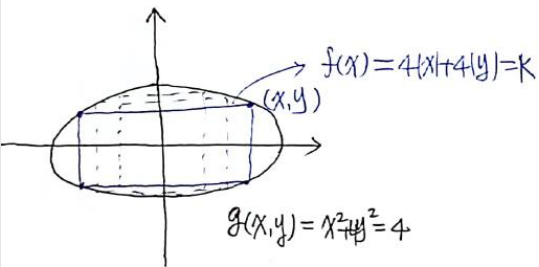
# 라그랑주 승수법의 예제

- 그림과 같이 제약 조건  $g(x, y) = x^2 + 4y^2 = 4$  를 만족하면서, 사각형의 네 변의 합을 최대화  $x, y$  를 구하라.




# 라그랑주 승수법의 예제

- 그림과 같이 제약 조건  $g(x, y) = x^2 + 4y^2 = 4$  를 만족하면서, 사각형의 네 변의 합을 최대화  $x, y$  를 구하라.



$$\begin{aligned} &\max_{x,y} f(x) \\ &\text{Subject to } g(x,y) = x^2 + y^2 = 4 \\ &\nabla f = \lambda \nabla g \\ &g(x,y) = x^2 + y^2 = 4 \\ &\nabla f = \left( \frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right) = (4, 4) \\ &\nabla g = \left( \frac{\partial g}{\partial x}, \frac{\partial g}{\partial y} \right) = (2x, 2y) \\ &\nabla f = \lambda \nabla g \quad \begin{cases} 4 = 2\lambda x \rightarrow x = \frac{4}{2\lambda} = \frac{2}{\lambda} \\ 4 = 2\lambda y \rightarrow y = \frac{4}{2\lambda} = \frac{2}{\lambda} \end{cases} \\ &g(x,y) = g\left(x = \frac{2}{\lambda}, y = \frac{2}{\lambda}\right) = \left(\frac{2}{\lambda}\right)^2 + \left(\frac{2}{\lambda}\right)^2 = \frac{4}{\lambda^2} + \frac{4}{\lambda^2} = \frac{8}{\lambda^2} \\ &\frac{8}{\lambda^2} = 4 \rightarrow \lambda^2 = \frac{8}{4} = 2 \quad \lambda = \pm\sqrt{2} \\ &x = \frac{2}{\lambda} = \pm\frac{2}{\sqrt{2}} = \pm\sqrt{2} \quad y = \frac{2}{\lambda} = \pm\frac{2}{\sqrt{2}} = \pm\sqrt{2} \\ &\therefore (x,y) = \left(\pm\sqrt{2}, \pm\sqrt{2}\right) \end{aligned}$$





# Duality 의 Lagrangian 승주법을 적용한 접근 방식

- 앞에서 언급한 primal problem 을 다시 작성해 보면,

$$\min_x c^T x \quad \leftarrow \text{최소화 하고자 하는 함수 } f$$

$$Ax = b \quad \leftarrow \text{제약조건 } g$$

$$Gx \leq h$$

$f^* \geq g(u, v)$  의 관계로 인하여  
primal 의 최소값을 찾는 것은  
 $g(u, v)$  즉, 라그랑지 듀얼 함수를 최  
대화 하는 문제와 동일하게 됨.

$$\max_{u, v} g(u, v)$$

Lagrange dual problem 의 의미 subject to  $u \geq 0$

- 라그랑지 듀얼 함수는  $f^*$  (primal 함수의 최적의 해) 에 대하여 모든  $v \geq 0, u$  에 대한 강력한 lower bound  $f^* \geq g(u, v)$  를 제공하며 이는 제약식이 있는 문제를 제약식이 없는 문제로 바꾸어 해당 식의 값을 더 작게 만들 수 있다는 의미가 있음.
- 따라서, 가능한 모든  $u$ 와  $v$  에 대하여  $g(u, v)$  를 최대화 함으로써 가장 좋은 lower bound 를 얻을 수 있음.

$$\nabla f - \lambda \nabla g = \nabla L = 0$$

$$L(x, y, \lambda) = f(x, y) - \lambda(g(x, y) - c)$$

$$= c^T x + u^T (Ax - b) + v^T (Gx - h)$$

$Ax - b = 0$  ( $Ax = b$ 에 의하여)이며  $Gx - h \leq 0$  ( $Gx \leq h$ )으로

$u^T (Ax - b) + v^T (Gx - h) \leq 0$ 이 되기 때문에

$$= L(x, y, \lambda) = c^T x + u^T (Ax - b) + v^T (Gx - h) \leq c^T x$$

$C$  를 원초 문제의 제약식을 만족하는  $x$ 의 집합,

$f^*$  를 찾으려고 하는 최적의 값이라고 할때,

이를 다시 풀어 수식화하면,

$$\therefore f^* \geq \min_{x \in C} L(x, u, v) \geq \min_x L(x, u, v) \text{ 식이 성립하게 되고}$$

$\min_x L(x, u, v) = g(u, v)$ 라고 하며

$g(u, v)$  는 라그랑지 듀얼 함수가 됨.

# 일반적인 최적화 문제에 Lagrangian 접근을 적용

- 아래와 같이 일반적인 primal problem 이 적용되어 있다고 가정.

$$\begin{array}{ll} \min_x & f(x) \\ \text{subject to} & h_i(x) \leq 0, \quad i = 1, \dots, m \\ & l_j(x) = 0, \quad j = 1, \dots, r \end{array}$$




Dual problem 으로 치환

- 이때, dual problem 은 primal problem 이 convex 가 아니어도 항상 convex optimization problem 이 됨.
  - Why? Dual 함수  $g(u, v)$  는 항상 convexity 를 보존하는 연산만 수행되기 때문.
  - 이것이 바로 primal problem 을 dual problem 으로 치환하여 문제를 해결해야 하는 이유라고 이해함.

$$\begin{aligned} L(x, u, v) &= f(x) + \sum_{i=1}^m u_i h_i(x) + \sum_{j=1}^r v_j l_j(x) \\ g(u, v) &= \min_x L(x, u, v) \end{aligned}$$

← 라그랑지 함수  $L$

← Dual 함수  $g$



$$\begin{array}{ll} \max_{u, v} & g(u, v) \\ \text{subject to} & u \geq 0 \end{array}$$

<Dual 함수>



<Dual problem>

<https://wikidocs.net/20584>

# convexity

- Convex function 의 정의
- 임의의 두 점  $x, y$  와  $[0,1]$  사이의 값  $t$  에 대해 다음이 항상 성립하는 함수  $f$  임.

$$f(tx + (1-t)y) \leq (1-t)f(y) + tf(x)$$



<convexity 가 중요한 이유>


- $t$  는  $x_2$  로 부터  
의 distance 임.

# Convex function 의 예시

---

# Convexity 의 special case

- Convexity 의 대표적인 부분집합(special case) 는 strong convexity 와 strict convexity 가 있음.



# Dual 함수가 convexity 성질을 보존하는 이유

## – pointwise maximization

- **convexity**를 보존하는 연산
- *convex function*에 대해 다음 연산은 **convexity**를 보존합니다.

**Pointwise maximization:** if  $f_s$  is convex for any  $s \in S$ , then  $f(x) = \max_{s \in S} f_s(x)$  is convex. Note that the set  $S$  here (number of functions  $f_s$ ) can be infinite

Another key property: the dual problem is a **convex optimization** problem (as written, it is a concave maximization problem)

Again, this is always true (even when primal problem is not convex)

By definition:

$$\begin{aligned} g(u, v) &= \min_x \left\{ f(x) + \sum_{i=1}^m u_i h_i(x) + \sum_{j=1}^r v_j \ell_j(x) \right\} \\ &= \underbrace{\max_x \left\{ -f(x) - \sum_{i=1}^m u_i h_i(x) - \sum_{j=1}^r v_j \ell_j(x) \right\}}_{\text{pointwise maximum of convex functions in } (u, v)} \end{aligned}$$


<https://ratsgo.github.io/convex%20optimization/2018/01/25/duality/>

# Dual 함수가 convexity 성질을 보존하는 이유

$$\begin{aligned} g(u, v) &= \min_x \left\{ f(x) + \sum_{i=1}^m u_i h_i(x) + \sum_{j=1}^r v_j l_j(x) \right\} \\ &= \underbrace{-\max_x \left\{ -f(x) - \sum_{i=1}^m u_i h_i(x) - \sum_{j=1}^r v_j l_j(x) \right\}}_{\text{pointwise maximum of convex functions in } (u, v)} \end{aligned}$$


- **concave function(오목함수)**  
란 *convex function*에 음수를 취한 함수를 지칭하는 것으로 *convex function*에 집중해서 분석할 수 있음.
- 이로 인하여 **dual** 문제는 **concave maximization** 문제에 해당 됨.

**Pointwise maximization:** if  $f_s$  is convex for any  $s \in S$ , then  $f(x) = \max_{s \in S} f_s(x)$  is convex. Note that the set  $S$  here (number of functions  $f_s$ ) can be infinite




## 예제 : Primal problem 이 nonconvex 일 경우

Primal



Dual



- Nonconvex 를 dual problem 으로 치환 concave 가 되도록 하여 문제를 쉽게 해결 할 수 있음.



# Duality gap

- Duality 의 목적함수  $g(u, v)$  를 최대화 하는 문제의 해와 primal problem 을 최소화 하는 문제의 해가 반드시 같지는 않다는 개념을 duality gap 이라고 함.
- $f^* \geq \min_x L(x, u, v) = g(u, v)$ 

$f^*$  의 최적의 값과  $g(u, v)$  의 최적의 값 사이에는 차이가 존재함.
- 이때, 특정 조건을 만족하면  $f^*$  의 최적의 값과  $g(u, v)$  의 최적의 값이 동치가 되는데 이 조건이 *Slater's condition* 임.

Given primal problem

$$\begin{aligned} \min_x \quad & f(x) \\ \text{subject to} \quad & h_i(x) \leq 0, \quad i = 1, \dots, m \\ & \ell_j(x) = 0, \quad j = 1, \dots, r \end{aligned}$$

**Slater's condition:** if the primal is a convex problem (i.e.,  $f$  and  $h_1, \dots, h_m$  are convex,  $\ell_1, \dots, \ell_r$  are affine), and there exists at least one strictly feasible  $x \in \mathbb{R}^n$ , meaning

$$h_1(x) < 0, \dots, h_m(x) < 0 \quad \text{and} \quad \ell_1(x) = 0, \dots, \ell_r(x) = 0$$

then strong duality holds

<https://ratsgo.github.io/convex%20optimization/2018/01/25/duality/>

<https://wikidocs.net/20583>

<https://pasus.tistory.com/91>